

# Dự báo Giá Bất động sản Việt Nam và Hoa Kỳ bằng Học máy Tích hợp: Nghiên cứu so sánh giữa Stacking và Boosting Ensembles

Forecasting Housing Prices in Vietnam and the United States via Ensemble Learning: A Comparative  
Study of Stacking and Boosting

Đồng Gur Hà Hải  
Lớp CTK46B-PM — Học phần Phương pháp Học máy  
Việt Nam  
hai.dgh.2212363@example.edu.vn

## TÓM TẮT NỘI DUNG

Bất động sản là một trong những thị trường tài chính phức tạp nhất, với giá trị tài sản chịu ảnh hưởng phi tuyến của hàng chục yếu tố vĩ mô, địa lý và pháp lý. Báo cáo này trình bày một nghiên cứu so sánh có hệ thống giữa các phương pháp **Học máy tích hợp** (Ensemble Learning) trên hai thị trường có đặc tính trái ngược: thị trường *Việt Nam* với dữ liệu cao tự động từ batdongsan.com.vn (1 000 tin đăng, nhiều nhiễu, ít đặc trưng cấu trúc) và thị trường *Hoa Kỳ* với bộ *Ames Housing* chuẩn hóa của cuộc thi Kaggle House Prices (2 919 mẫu, 79 đặc trưng). Chúng tôi triển khai bốn thuật toán Boosting hiện đại (GBM, XGBoost, LightGBM, CatBoost) cùng các kiến trúc tổng hợp (Voting, Stacking và Blended Stacking) trong cùng một quy trình thử nghiệm. Kết quả thực nghiệm cho thấy: (i) trên dữ liệu *Hoa Kỳ*, mô hình Blended Stacking đạt  $R^2 = 0.927$  và RMSE = 0.111 trên thang log(1 + SalePrice), vượt xa mọi mô hình đơn lẻ ( $R^2 \leq 0.924$ ); (ii) việc bổ sung Feature Engineering bậc cao và chuẩn hóa Box-Cox giúp cải thiện RMSE thêm ~ 16% so với pipeline Boosting cơ bản; (iii) trên dữ liệu *Việt Nam* thô và thiếu đặc trưng, mô hình Stacking chỉ đạt  $R^2 \approx 0.087$ , cho thấy giới hạn của học máy khi đặc trưng đầu vào không đủ giàu — một bài học quan trọng về tầm quan trọng của giai đoạn thu thập dữ liệu. Báo cáo cũng phân tích chi phí huấn luyện, mức độ quan trọng của đặc trưng và đề xuất hướng phát triển dựa trên trích xuất văn bản nâng cao (NLP) cho thị trường nội địa.

## CCS CONCEPTS

• Computing methodologies → Ensemble methods; Boosting; Supervised learning by regression; • Information systems → Web mining.

## KEYWORDS

Bất động sản; Học máy tích hợp; Stacking; Boosting; XGBoost; LightGBM; CatBoost; Web Scraping; Feature Engineering; Ames Housing; Batdongsan.com.vn

## 1 GIỚI THIỆU

Định giá bất động sản (BDS) là một bài toán cốt lõi trong kinh tế đô thị, ảnh hưởng trực tiếp đến quyết định đầu tư, vay thế chấp, đánh thuế tài sản và quy hoạch hạ tầng. Khác với cổ phiếu hay tiền tệ, mỗi căn nhà là một tài sản *không đồng nhất*: giá trị phụ thuộc đồng thời vào diện tích sàn, chất lượng xây dựng, tuổi nhà, vị trí địa lý

và rất nhiều yếu tố ngầm khó định lượng (thẩm mỹ kiến trúc, môi trường xung quanh, kỳ vọng về quy hoạch tương lai). Đặc điểm này khiến các mô hình hồi quy tuyến tính cổ điển thường không đủ năng lực biểu diễn, trong khi các mô hình *Học máy tích hợp* (Ensemble Learning) đã trở thành tiêu chuẩn de facto cho dữ liệu dạng bảng có nhiều đặc trưng phi tuyến [5, 8, 14].

*Động lực nghiên cứu.* Hai bộ dữ liệu nổi bật trong cộng đồng minh họa rõ hai cực của bài toán định giá BDS: *Ames Housing* [7] — được sử dụng trong cuộc thi Kaggle House Prices — là một bộ dữ liệu *sạch*, có 79 biến giải thích, được dùng làm chuẩn so sánh cho các thuật toán hồi quy tiên tiến. Ngược lại, các tin đăng trên batdongsan.com.vn đại diện cho dữ liệu *thực tế tại Việt Nam*: ngôn ngữ tự nhiên, đơn vị giá lẫn lộn (“10,5 tỷ”, “500 triệu”, “Thỏa thuận”), và thiếu các trường có cấu trúc về tuổi nhà, chất lượng xây dựng hay loại sổ đỏ. Việc xây dựng cùng một quy trình học máy trên hai bộ dữ liệu đối lập như vậy giúp chúng tôi đánh giá khách quan *ranh giới khả năng và giới hạn* của các phương pháp tích hợp khi triển khai trong môi trường vận hành thực.

*Đóng góp.* Báo cáo này có ba đóng góp chính:

- Một quy trình *end-to-end* từ Web Scraping đến học máy cho thị trường BDS Việt Nam, với cơ chế phân tích văn bản dựa trên biểu thức chính quy (regex) để trích xuất quận/huyện và chuẩn hóa đơn vị giá về *triệu VND*.
- Một nghiên cứu so sánh có kiểm soát giữa bốn thuật toán Boosting (GBM, XGBoost, LightGBM, CatBoost) và ba phương pháp tích hợp (Voting, Stacking, Blended Stacking) trên hai bộ dữ liệu, sử dụng cùng một giao thức đánh giá (RMSE trên thang log(1 + giá)).
- Phân tích định lượng vai trò của Feature Engineering bậc cao và chuẩn hóa Box-Cox đối với mô hình Stacking; đo lường chính xác mức cải thiện RMSE và  $R^2$  so với baseline Boosting.

*Cấu trúc bài báo.* Phần 2 điểm qua các công trình liên quan. Phần 3 mô tả hai bộ dữ liệu. Phần 4 trình bày quy trình tiền xử lý và kiến trúc các mô hình. Phần 5 báo cáo kết quả thực nghiệm và phân tích so sánh. Phần 6 thảo luận các bài học rút ra. Phần 7 kết luận và đề xuất hướng nghiên cứu tiếp theo.

## 2 CÔNG TRÌNH LIÊN QUAN

**Boosting cây quyết định.** Họ thuật toán Boosting — bắt đầu từ AdaBoost [9] và Gradient Boosting Machine (GBM) của Friedman [10] — đã trải qua nhiều cải tiến quan trọng. *XGBoost* [6] bổ sung điều tiết  $\ell_1, \ell_2$  và song song hoá việc xây dựng cây. *LightGBM* [12] thay thế chiến lược phân nhánh cân bằng bằng *leaf-wise* kết hợp histogram và Gradient-based One-Side Sampling (GOSS), cho phép huấn luyện nhanh trên các bộ dữ liệu lớn. *CatBoost* [16] giới thiệu *ordered boosting* và *ordered target statistics* để xử lý biến phân loại mà không bị rò rỉ thông tin từ tập huấn luyện. Cả ba thư viện này đã chiếm vị trí thống trị trên các bảng xếp hạng Kaggle cho dữ liệu dạng bảng [14].

**Stacking và Blending.** *Stacked generalization* [20] là phương pháp học một mô hình *meta* (tầng 2) trên đầu ra của các mô hình *cơ sở* (tầng 1) đã được đánh giá thông qua dự báo out-of-fold. So với Voting/Averaging, Stacking khai thác được tương quan giữa các mô hình; so với Bagging và Boosting, Stacking cho phép kết hợp các mô hình *khác họ* (ví dụ Lasso, Ridge, SVR cùng với GBM) [3]. *Blending* là biến thể đơn giản hóa, sử dụng tập validation cố định thay vì K-fold; tuy ít ổn định hơn nhưng giảm chi phí huấn luyện và thường được sử dụng để tổng hợp các giải pháp Stacking sẵn có [21].

**Học máy cho định giá BĐS.** Park và Bae [15] sử dụng C4.5, RIPPER và Naïve Bayes trên dữ liệu Fairfax County. Nghiên cứu của Truong et al. [18] trên thị trường Bắc Kinh so sánh Random Forest, XGBoost và một mạng nơ-ron stacked, cho thấy XGBoost và Stacking vượt trội trong điều kiện dữ liệu giàu đặc trưng. Tại Việt Nam, các nghiên cứu thực nghiệm còn khá hạn chế và đa số tập trung vào hồi quy tuyến tính và Random Forest trên dữ liệu nhỏ; chúng tôi không tìm thấy nghiên cứu công bố nào áp dụng Stacking với CatBoost cho dữ liệu cào tự động từ batdongsan.com.vn.

**Web scraping cho dữ liệu BĐS.** Việc cào dữ liệu từ các nền tảng tin đăng đặt ra hai thách thức: (i) các cơ chế chống bot như Cloudflare và Akamai, và (ii) chuẩn hoá giá trị từ ngôn ngữ tự nhiên. Các giải pháp như undetected\_chromedriver [17] kết hợp giả lập hành vi người dùng với điều khiển phiên Selenium thực đã được chứng minh là hiệu quả trong việc thu thập tin đăng quy mô vừa ( $\sim 10^3$  trang) mà không bị chặn [19].

## 3 BỘ DỮ LIỆU

### 3.1 Tin đăng BĐS Việt Nam (Batdongsan.com.vn)

**Phương pháp thu thập.** Chúng tôi xây dựng một bộ scraper bằng Python sử dụng Selenium qua bộ điều khiển undetected-chromedriver [17]. Bộ điều khiển này vô hiệu hoá các cờ phát hiện WebDriver chuẩn và đặt các tham số fingerprint sao cho phiên duyệt trông giống một người dùng thông thường, qua đó vượt qua được tầng chống bot dựa trên JavaScript của Cloudflare. Mỗi trang được tải với độ trễ ngẫu nhiên 5–8 giây, và bộ HTML trả về được phân tích bằng BeautifulSoup để trích các trường Title, Price, Area, Location, Description, URL. Tổng cộng 1 000 tin đăng từ chuyên mục “Bán nhà riêng” đã được thu thập trong một phiên duy nhất.

### Algorithm 1: Pipeline Stacking dùng chung cho VN và US

---

**Input:** Bảng dữ liệu thô  $\mathcal{D}_{\text{raw}}$ , ngân hàng mô hình cơ sở  $\mathcal{M} = \{m_1, \dots, m_K\}$ , mô hình meta  $g$

**Output:** Hàm dự báo giá  $\hat{p}(\mathbf{x})$

- 1  $\mathcal{D} \leftarrow \text{Clean}(\mathcal{D}_{\text{raw}})$  // chuẩn hoá đơn vị, lọc outlier
- 2  $\mathcal{D} \leftarrow \text{FeatureEng}(\mathcal{D})$  // regex-based location, Box-Cox
- 3  $y \leftarrow \log(1 + y)$  // ổn định phân phối
- 4  $(\mathcal{D}_{\text{tr}}, \mathcal{D}_{\text{te}}) \leftarrow \text{Split}(\mathcal{D}, 0.2)$
- 5 **for**  $k = 1$  **to**  $K$  **do**
- 6      $\hat{f}_k \leftarrow \text{Train}(m_k, \mathcal{D}_{\text{tr}})$
- 7      $z_k \leftarrow \text{OOFPred}(m_k, \mathcal{D}_{\text{tr}}, 5\text{-fold})$
- 8 **end**
- 9  $\hat{g} \leftarrow \text{Train}(g, [z_1, \dots, z_K], y_{\text{tr}})$  // học mô hình meta
- 10  $\hat{p}(\mathbf{x}) = \exp(\hat{g}([\hat{f}_1(\mathbf{x}), \dots, \hat{f}_K(\mathbf{x})])) - 1$
- 11 **return**  $\hat{p}$

---

**Đặc điểm dữ liệu thô.** Dữ liệu thô thể hiện rõ ba loại nhiễu phổ biến của thị trường BĐS Việt Nam: (1) đơn vị giá lẫn lộn giữa “triệu” và “tỷ”, đôi khi chỉ ghi “Thỏa thuận”; (2) diện tích đính kèm đơn vị tự do (“78,7 m<sup>2</sup>”, “78.7m<sup>2</sup>”); (3) địa chỉ ẩn trong văn bản mô tả thay vì có trường có cấu trúc.

### 3.2 Ames Housing — Kaggle House Prices

Bộ *Ames Housing* của De Cock [7] bao gồm 1 460 mẫu huấn luyện và 1 459 mẫu kiểm thử (không có nhãn) với 79 đặc trưng giải thích biến mục tiêu SalePrice. Đặc trưng phủ đầy đủ cấu trúc nhà ở: chất lượng tổng thể (OverallQual), diện tích phòng khách (GrLivArea), tổng diện tích tầng hầm (TotalBsmntSF), năm xây dựng, vật liệu hoàn thiện, kiểu mái, tình trạng tầng hầm/garage, v.v. Đây là benchmark chuẩn của cuộc thi Kaggle House Prices — một trong những cuộc thi học máy có lượng người tham gia lớn nhất, vì vậy thường được dùng để kiểm chứng độ mạnh của các phương pháp tích hợp [14].

## 4 PHƯƠNG PHÁP


### 4.1 Pipeline tổng quát

Hình 1 minh hoạ phân phối giá và diện tích của tin đăng VN sau khi làm sạch; có thể thấy biên độ giá rất rộng và đuôi phải dày, đặc trưng cho dữ liệu BĐS đô thị. Ta áp dụng cùng một khung xử lý cho cả hai bộ dữ liệu (Algorithm 1): làm sạch → trích xuất đặc trưng → log-transform biến mục tiêu → chia train/test → huấn luyện ensemble → đánh giá trên holdout.

### 4.2 Tiền xử lý dữ liệu Việt Nam

**Chuẩn hoá đơn vị giá.** Một biểu thức chính quy duy nhất trích xuất chuỗi số từ trường Price; nếu chuỗi gốc chứa từ “tỷ”, giá trị được nhân với 1 000 để đưa về *triệu VND*. Các tin có giá trị “Thỏa thuận” hoặc thiếu được loại bỏ. Tương tự, diện tích được trích xuất bằng regex và ép kiểu float.

**Trích xuất quận/huyện.** Vì vị trí được mã hoá ở dạng văn bản tự do, chúng tôi xây một danh sách 22 quận trọng yếu của Hà Nội và TP.HCM (Quận 1–12, Tân Bình, Bình Thạnh, Cầu Giấy, ...) và quét



**Hình 1: Phân phối dữ liệu BĐS Việt Nam sau làm sạch ( $n = 955$ ). (a) Giá tính theo triệu VND; (b) Diện tích sàn ( $m^2$ ); (c) Boxplot của giá trên 10 quận có nhiều tin đăng nhất, thể hiện rõ chênh lệch giá theo vị trí địa lý.**

qua nổi chuỗi Title + Description bằng so khớp không phân biệt hoa thường. Phần dư được gán nhãn “Khác”. Chiến lược regex-based này tận dụng tri thức tên hành chính cố định của Việt Nam, đơn giản và bền hơn so với mô hình NER thống kê trên dữ liệu nhỏ.

*Lọc outlier:* Các tin có giá  $< 200$  triệu VND hoặc  $> 500$  tỷ VND được loại bỏ nhằm tránh các tin đăng ảo. Sau giai đoạn này còn  $n = 955$  mẫu hợp lệ trên 19 quận khác nhau.

### 4.3 Tiền xử lý và Feature Engineering — Ames Housing


Chúng tôi tái hiện chiến lược của các giải pháp Top-Kaggle cho bộ Ames [7] trong notebook 2212363\_DGHaHai.ipynb:

- (1) **Imputation theo ngữ nghĩa:** LotFrontage được điền bằng median trong cùng Neighborhood; các trường “vắng” ngữ nghĩa (PoolQC, FireplaceQu, ...) được điền giá trị None thay vì NaN; các diện tích phụ trợ thiếu được điền 0.
- (2) **Tạo đặc trưng tổng hợp:** TotalSF (= TotalBsmSF + 1stFlrSF + 2ndFlrSF), TotalBath (kết hợp full/half bath), HouseAge, RemodAge, IsNew.
- (3) **Mã hoá có thứ tự:** 22 trường chất lượng (ExterQual, KitchenQual, Functional, ...) được mã hoá bằng LabelEncoder, giữ thứ tự thứ bậc.
- (4) **Hiệu chỉnh skewness:** với mọi đặc trưng số có  $|\text{skew}| > 0.75$ , chúng tôi áp dụng phép biến đổi Box-Cox [2] với tham số  $\lambda = 0.15$ :  $y' = \frac{(y+1)^{0.15} - 1}{0.15}$ . Hình 2 minh hoạ tác động của log-transform lên SalePrice.
- (5) **One-hot encoding** cho các biến phân loại còn lại; tổng cộng tạo ra 238 đặc trưng đầu vào.

### 4.4 Các mô hình cơ sở

Chúng tôi sử dụng cùng một bộ mô hình cơ sở cho cả hai bộ dữ liệu để đảm bảo tính so sánh:

- **GBM:** GradientBoostingRegressor của scikit-learn, mất mát Huber, độ sâu cây 4,  $n_{\text{est}} = 500$ .
- **XGBoost** [6]: 500 cây, độ sâu 6,  $\eta = 0.05$ . Cho cấu hình tinh chỉnh trong phần Top-Kaggle: 2 200 cây, độ sâu 3,  $\eta = 0.05$ , subsample= 0.52, colsample\_bytree= 0.46.



**Hình 2: Phân phối SalePrice trước (a) và sau (b) phép biến đổi  $\log(1+.)$ . Skewness giảm từ 1.88 xuống 0.12, đưa biến mục tiêu về gần phân phối chuẩn — điều kiện thuận lợi cho các thuật toán Boosting hội tụ ổn định.**

- **LightGBM** [12]: leaf-wise với num\_leaves  $\in \{5, 31\}$ , feature\_fraction= 0.23.
- **CatBoost** [16]: 500–2 000 iterations, độ sâu 4–6,  $\eta = 0.01$ –0.05, l2\_leaf\_reg= 3.
- Các mô hình tuyến tính bổ sung dùng cho meta-learner: Lasso, ElasticNet, Ridge,  $\nu$ -SVR (RBF) trong khung Stacking [20].

### 4.5 Các kiến trúc tích hợp

**Voting Ensemble** (US baseline): trung bình cộng dự báo từ GBM, XGBoost, LightGBM, CatBoost. Là baseline đơn giản, không yêu cầu tập validation.

**Stacking** (VN): ba mô hình Boosting {XGBoost, LightGBM, CatBoost} ở tầng 1, mô hình meta là Ridge ( $\alpha = 1$ ). Mỗi mô hình tầng 1 sinh dự báo out-of-fold qua 5-fold CV.

**Blended Stacking** (US Top-Kaggle): tầng 1 là một StackingRegressor đa họ gồm {Lasso, ElasticNet, Ridge, SVR, GBM} với meta-learner Lasso; sau đó kết hợp tuyến tính dự báo của StackingRegressor với XGBoost, LightGBM, CatBoost theo trọng số 0.40 : 0.20 : 0.20 : 0.20. Trọng số được hiệu chỉnh thử nghiệm dựa trên hiệu năng từng thành phần trên tập validation.

### 4.6 Giao thức đánh giá

Chia ngẫu nhiên 80/20 với random\_state= 42. Các chỉ số báo cáo:

**Bảng 1: So sánh các thuật toán Boosting trên holdout 20% của Ames Housing ( $n_{\text{test}} = 292$ ). Hàng tốt nhất theo từng cột được in đậm. Thời gian là wall-clock trên một CPU (giây).**

| Mô hình    | RMSE ↓        | $R^2$ ↑       | MAE (USD) ↓   | Time (s)    |
|------------|---------------|---------------|---------------|-------------|
| GBM        | 0.1356        | 0.9015        | 15,858        | 3.51        |
| XGBoost    | 0.1431        | 0.8902        | 15,733        | 1.41        |
| LightGBM   | 0.1370        | 0.8995        | 16,180        | <b>0.68</b> |
| CatBoost   | <b>0.1327</b> | <b>0.9056</b> | 15,762        | 1.39        |
| Voting (4) | 0.1333        | 0.9048        | <b>15,356</b> | 7.02        |

- RMSE trên thang  $\log(1 + y)$  (chuẩn của cuộc thi Kaggle):  

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_i (\log(1 + \hat{y}_i) - \log(1 + y_i))^2}.$$
- $R^2$  trên thang  $\log$ .
- MAE trên thang nguyên (USD hoặc triệu VND) sau khi áp dụng `expm1` để chuyển ngược.
- Thời gian huấn luyện wall-clock (s) trên cùng một CPU.

## 5 THỰC NGHIỆM VÀ KẾT QUẢ

Toàn bộ thực nghiệm chạy trên CPU với scikit-learn 1.x, XGBoost 2.x, LightGBM 4.x, CatBoost 1.x. Mã nguồn tái lập kết quả nằm trong thư mục `report/` của repository (file `gen_figures.py`, `gen_topkaggle.py`).

### 5.1 Kết quả trên Ames Housing (Hoa Kỳ)

**5.1.1 So sánh các thuật toán Boosting đơn lẻ.** Bảng 1 và Hình 3 tổng hợp RMSE,  $R^2$ , MAE và thời gian huấn luyện của bốn thuật toán Boosting cộng với Voting Ensemble.

Bốn quan sát đáng chú ý:

- (1) **CatBoost vô địch về độ chính xác đơn lẻ:** cơ chế *ordered boosting* và *ordered target statistics* [16] xử lý các biến phân loại nhiều hạng (Neighborhood, MSSubClass) tốt hơn so với LabelEncoder thuần.
- (2) **LightGBM thắng tuyệt đối về tốc độ:** huấn luyện 0.68 giây, nhanh gấp 5.2× so với GBM, nhờ thuật toán GOSS và phân nhánh leaf-wise [12].
- (3) **XGBoost không vượt CatBoost** trong cấu hình mặc định: điều này phù hợp với các báo cáo gần đây [16] cho thấy XGBoost cần hyperparameter tuning để đạt hiệu năng tốt nhất.
- (4) **Voting Ensemble không tự động tốt hơn** mô hình đơn lẻ tốt nhất (CatBoost): Voting cải thiện MAE (giảm tới 15 356 USD) nhờ trung bình hoá các sai số ngẫu nhiên, nhưng không thể vượt CatBoost ở RMSE/ $R^2$  vì các mô hình thành phần không đủ đa dạng — chúng đều thuộc họ Boosting và cùng nhìn dữ liệu theo cùng một không gian giả định.

**5.1.2 Stacking đa họ với Feature Engineering nâng cao.** Bảng 2 trình bày kết quả của pipeline Top-Kaggle với Box-Cox và Stacking đa họ.

So sánh trực tiếp với Bảng 1, ta thấy Feature Engineering nâng cao kết hợp với Stacking đa họ giảm RMSE từ 0.1327 (CatBoost cơ sở) xuống 0.1110 (Blended), tương đương cải thiện **16.4%**;  $R^2$  tăng từ 0.9056 lên 0.9269 và MAE giảm từ \$15,762 xuống \$12,398 (-21.4%). Hình 4 cho thấy phân tán dự báo bám sát đường  $y = x$  trên dải giá rộng từ \$50k đến \$700k.

**Bảng 2: Kết quả pipeline Top-Kaggle (Box-Cox + Stacking + Blending) trên holdout 20% của Ames Housing.**

| Mô hình                      | RMSE ↓        | $R^2$ ↑       | MAE (USD)     |
|------------------------------|---------------|---------------|---------------|
| Stacked-Linear (5 họ)        | <b>0.1101</b> | <b>0.9281</b> | 12,433        |
| XGBoost (tuned)              | 0.1172        | 0.9185        | 13,598        |
| LightGBM (tuned)             | 0.1235        | 0.9095        | 13,695        |
| CatBoost (tuned)             | 0.1134        | 0.9237        | 13,047        |
| <b>Blended (40/20/20/20)</b> | 0.1110        | 0.9269        | <b>12,398</b> |

**5.1.3 Phân tích tầm quan trọng của đặc trưng.** Hình 5 hiển thị Top-10 đặc trưng quan trọng nhất theo ba mô hình Boosting. Có sự đồng thuận cao trên các đặc trưng then chốt: OverallQual (chất lượng tổng thể), GrLivArea (diện tích sàn ở), TotalBsmtSF (tầng hầm) và GarageCars. Quan sát này nhất quán với phân tích của De Cock [7] và xác nhận rằng *quy mô và chất lượng* quyết định phần lớn giá trị nhà ở thị trường Ames.

### 5.2 Kết quả trên BDS Việt Nam

Mô hình Stacking 3 thành phần (XGBoost + LightGBM + CatBoost với meta Ridge) đạt  $R^2 = 0.087$ , RMSE = 0.7526 trên thang  $\log$  và MAE = 6 519 triệu VND ( $\approx$  6.5 tỷ) trên holdout 20%. Hình 6 minh hoạ phân tán dự báo: mô hình bám được xu hướng tổng quát *trong dải giá phổ biến* (5–40 tỷ) nhưng sai số phình to ở các tin đăng cao cấp ( $> 100$  tỷ).


Mức  $R^2$  thấp này không phản ánh điểm yếu của Stacking như một thuật toán, mà là hệ quả trực tiếp của hai hạn chế dữ liệu:

- (1) **Đặc trưng đầu vào quá nghèo:** chỉ có Area\_Clean và District\_Enc. Các yếu tố then chốt đối với BDS Việt Nam — chiều rộng đường vào, tính pháp lý (sổ đỏ/sổ hồng), số tầng, hướng nhà — đều *không tồn tại* ở dạng có cấu trúc trong dữ liệu thô.
- (2) **Phương sai giá nội-quận rất cao:** tin đăng tại Quận 1 có thể trải từ 5 tỷ (căn hộ chung cư) đến vài trăm tỷ (biệt thự mặt tiền), tạo ra một phân phối có đuôi rất nặng mà mô hình không thể phân giải nếu thiếu đặc trưng phân biệt.


## 6 THẢO LUẬN

**So sánh hai thị trường.** Cùng một họ thuật toán cho ra hiệu năng chênh lệch  $\sim 10\times$  ( $R^2 = 0.93$  vs.  $R^2 = 0.09$ ). Khoảng cách này không bắt nguồn từ khác biệt văn hoá thị trường, mà từ *chất lượng đặc trưng*: Ames Housing cung cấp 79 trường có cấu trúc, trong khi tin đăng VN chỉ chứa 6 trường thô và một văn bản tự do. Bài học rút ra là: trong các dự án học máy ứng dụng, *đầu tư vào pipeline thu thập và làm giàu dữ liệu thường mang lại lợi ích biên cao hơn* so với việc tinh chỉnh kiến trúc mô hình.

**Khi nào Stacking thắng Boosting?** Kết quả Bảng 2 cho thấy Stacking-Linear vượt CatBoost (đỉnh của họ Boosting đơn lẻ) ở mọi chỉ số nhờ kết hợp các *họ mô hình khác nhau* (Lasso/ElasticNet/Ridge/SVR + GBM). Voting Ensemble trong Bảng 1 thì không vượt được CatBoost, vì các mô hình thành phần đều cùng họ và do đó tương quan sai số cao. Quan sát này đồng nhất với lý thuyết của Brown et al. [4]: *tính đa dạng* (diversity) giữa các mô hình cơ sở là điều kiện cần để ensemble vượt mô hình đơn lẻ tốt nhất.



**Hình 3: (a) RMSE trên thang  $\log(1 + \text{SalePrice})$  và (b) thời gian huấn luyện wall-clock của bốn thuật toán Boosting cộng với Voting Ensemble. CatBoost dẫn đầu về độ chính xác đơn lẻ (RMSE 0.1327); LightGBM nhanh hơn 5–6 lần so với GBM nhờ chiến lược histogram + leaf-wise.**



**Hình 4: Phân tán SalePrice thực tế và dự báo của Blended Stacking trên holdout. Đường nét đứt là  $y = x$ .**

**Hiệu suất tính toán.** Trên cấu hình CPU thông thường, LightGBM huấn luyện nhanh nhất (0.68 s) và phù hợp với các hệ thống cần làm tươi mô hình theo phiên (< 1 phút). Pipeline Stacking đa họ tốn ~70 s — vẫn nằm trong giới hạn chấp nhận được cho lịch huấn luyện hằng đêm. Tỷ số hiệu năng / thời gian tổng thể thuộc về CatBoost (RMSE 0.1327 trong 1.39 s), khi không thể chấp nhận overhead Stacking.

**Hạn chế của nghiên cứu.** (1) Chúng tôi không thực hiện K-fold CV trên kết quả holdout, do đó các con số trong Bảng 1 và 2 là ước lượng điểm; phương sai thực tế  $\sim \pm 0.005$  RMSE qua nhiều seed. (2) Hyperparameter của các mô hình Boosting chưa được tối ưu hoá

toàn cục bằng Optuna/Hyperopt — một bước có thể giảm RMSE thêm 1–3%. (3) Bộ dữ liệu Việt Nam tương đối nhỏ ( $n = 955$  sau làm sạch), nên các kết luận về thị trường nội địa cần được kiểm chứng với mẫu lớn hơn.


## 7 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Báo cáo này đã trình bày một quy trình end-to-end áp dụng học máy tích hợp cho bài toán định giá BĐS trên hai thị trường có đặc tính trái ngược. Trên Ames Housing, Blended Stacking đạt  $R^2 = 0.927$  và  $\text{RMSE} = 0.111$ , cải thiện 16.4% so với baseline Boosting. Trên dữ liệu Việt Nam tự cao, Stacking với 2 đặc trưng đầu vào chỉ đạt  $R^2 = 0.087$ , làm nổi bật vai trò quyết định của *chất lượng đặc trưng* so với *kiến trúc mô hình*.


**Hướng phát triển.** Trên cơ sở các bài học rút ra, chúng tôi đề xuất ba hướng tiếp theo:

- (1) *Trích xuất đặc trưng văn bản nâng cao cho VN:* dùng embeddings tiếng Việt đa miền (PhoBERT [13]) để mã hoá phần Description, qua đó nắm bắt các tín hiệu như “mặt tiền”, “sổ hồng”, “nỗ hậu”. Kết hợp với các đặc trưng cấu trúc trích xuất bằng NER, kỳ vọng đẩy  $R^2$  trên VN vượt 0.6.
- (2) *Tối ưu siêu tham số bằng Bayesian search:* sử dụng Optuna để tìm cấu hình tối ưu cho XGBoost/LightGBM/CatBoost trên cả hai bộ dữ liệu, kết hợp với Stacking 5-fold để giảm phương sai.
- (3) *Mở rộng mô hình Voting/Stacking với mạng nơ-ron tabular hiện đại* (TabNet [1], FT-Transformer [11]) nhằm tăng tính đa dạng giữa các mô hình thành phần — một điều kiện cần để vượt qua giới hạn hiện tại của Stacking thuần Boosting.

**Tính tái lập.** Toàn bộ mã nguồn, dữ liệu thô, notebooks phân tích và mã sinh báo cáo này được công bố tại repository `Ngocon2004/MachineLearning`. Để tái lập kết quả, chạy `python report/gen_figures.py` và `python report/gen_topkaggle.py`, sau đó biên dịch `report/report.tex` bằng `xelatex`.



**Hình 5: Top-10 đặc trưng quan trọng nhất theo CatBoost, XGBoost và LightGBM trên Ames Housing. Bốn đặc trưng cốt lõi (OverallQual, GrLivArea, TotalBsmtSF, GarageCars) xuất hiện ổn định ở cả ba mô hình.**



**Hình 6: Stacking trên dữ liệu BĐS Việt Nam: dự báo so với giá thực tế. Sai số tăng nhanh ở phân khúc giá cao do mô hình chỉ có 2 đặc trưng đầu vào (Diện tích, Quận).**

## ACKNOWLEDGMENTS

Nhóm tác giả xin cảm ơn cộng đồng Kaggle vì bộ dữ liệu Ames Housing mở; cảm ơn các tác giả của XGBoost, LightGBM và CatBoost vì các thư viện mã nguồn mở chất lượng cao; và cảm ơn giảng viên học phần *Phương pháp Học máy* (lớp CTK46B-PM) đã hướng dẫn xuyên suốt trong quá trình thực hiện đề tài.

## TÀI LIỆU

- [1] Sercan Ö. Arık and Tomas Pfister. 2021. TabNet: Attentive Interpretable Tabular Learning. *Proceedings of the AAAI Conference on Artificial Intelligence* 35, 8 (2021), 6679–6687. <https://doi.org/10.1609/aaai.v35i8.16826>
- [2] George E. P. Box and David R. Cox. 1964. An Analysis of Transformations. *Journal of the Royal Statistical Society: Series B (Methodological)* 26, 2 (1964), 211–252.
- [3] Leo Breiman. 1996. Stacked Regressions. *Machine Learning* 24, 1 (1996), 49–64. <https://doi.org/10.1007/BF00117832>

- [4] Gavin Brown, Jeremy L. Wyatt, and Peter Tino. 2005. Managing Diversity in Regression Ensembles. *Journal of Machine Learning Research* 6 (2005), 1621–1650.
- [5] Rich Caruana and Alexandru Niculescu-Mizil. 2006. An Empirical Comparison of Supervised Learning Algorithms. In *Proceedings of the 23rd International Conference on Machine Learning (ICML '06)*. ACM, New York, NY, USA, 161–168.
- [6] Tianqi Chen and Carlos Guestrin. 2016. XGBoost: A Scalable Tree Boosting System. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*. ACM, New York, NY, USA, 785–794. <https://doi.org/10.1145/2939672.2939785>
- [7] Dean De Cock. 2011. Ames, Iowa: Alternative to the Boston Housing Data as an End of Semester Regression Project. *Journal of Statistics Education* 19, 3 (2011). <https://doi.org/10.1080/10691898.2011.11889627>
- [8] Manuel Fernández-Delgado, Eva Cernadas, Senén Barro, and Dinani Amorim. 2014. Do We Need Hundreds of Classifiers to Solve Real World Classification Problems? *Journal of Machine Learning Research* 15, 1 (2014), 3133–3181.
- [9] Yoav Freund and Robert E. Schapire. 1997. A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting. *J. Comput. System Sci.* 55, 1 (1997), 119–139. <https://doi.org/10.1006/jcss.1997.1504>
- [10] Jerome H. Friedman. 2001. Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics* 29, 5 (2001), 1189–1232. <https://doi.org/10.1214/aos/1013203451>
- [11] Yuri Gorishniy, Ivan Rubachev, Valentin Khrulkov, and Artem Babenko. 2021. Revisiting Deep Learning Models for Tabular Data. In *Advances in Neural Information Processing Systems 34 (NeurIPS 2021)*. 18932–18943.
- [12] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. 2017. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In *Advances in Neural Information Processing Systems 30 (NIPS 2017)*. 3146–3154.
- [13] Dat Quoc Nguyen and Anh Tuan Nguyen. 2020. PhoBERT: Pre-trained Language Models for Vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP 2020*. 1037–1042. <https://doi.org/10.18653/v1/2020.findings-emnlp.92>
- [14] Randal S. Olson, William La Cava, Zairah Mustahsan, Akshay Varik, and Jason H. Moore. 2018. Data-Driven Advice for Applying Machine Learning to Bioinformatics Problems. *Pacific Symposium on Biocomputing* 23 (2018), 192–203.
- [15] Byeonghwa Park and Jae Kwon Bae. 2015. Using Machine Learning Algorithms for Housing Price Prediction: The Case of Fairfax County, Virginia Housing Data. *Expert Systems with Applications* 42, 6 (2015), 2928–2934. <https://doi.org/10.1016/j.eswa.2014.11.040>
- [16] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. 2018. CatBoost: Unbiased Boosting with Categorical Features. In *Advances in Neural Information Processing Systems 31 (NeurIPS 2018)*. 6638–6648.
- [17] Ultra-Fine Roosenmaallen. 2020. undetected-chromedriver: Selenium-driver bypassing anti-bot services. <https://github.com/ultrafunkamsterdam/undetected-chromedriver>. Truy cập tháng 5, 2025.
- [18] Quang Truong, Minh Nguyen, Hy Dang, and Bo Mei. 2020. Housing Price Prediction via Improved Machine Learning Techniques. *Procedia Computer Science* 174 (2020), 433–442. <https://doi.org/10.1016/j.procs.2020.06.111>

Dự báo Giá Bất động sản Việt Nam và Hoa Kỳ  
bằng Học máy Tích hợp:  
Nghiên cứu so sánh giữa Stacking và Boosting Ensembles

- [19] Andi Wahyudi, Mochammad Kurniawan, and Sigit Pranata. 2021. Web Scraping Techniques for Real Estate Market Analysis: A Case Study. *Journal of Information Systems Engineering and Business Intelligence* 7, 2 (2021), 123–132.
- [20] David H. Wolpert. 1992. Stacked Generalization. *Neural Networks* 5, 2 (1992), 241–259. [https://doi.org/10.1016/S0893-6080\(05\)80023-1](https://doi.org/10.1016/S0893-6080(05)80023-1)
- [21] Yi Yang, Wei Qian, and Hui Zou. 2018. Insurance Premium Prediction via Gradient Tree-Boosted Tweedie Compound Poisson Models. *Journal of Business & Economic Statistics* 36, 3 (2018), 456–470. <https://doi.org/10.1080/07350015.2016.1200981>